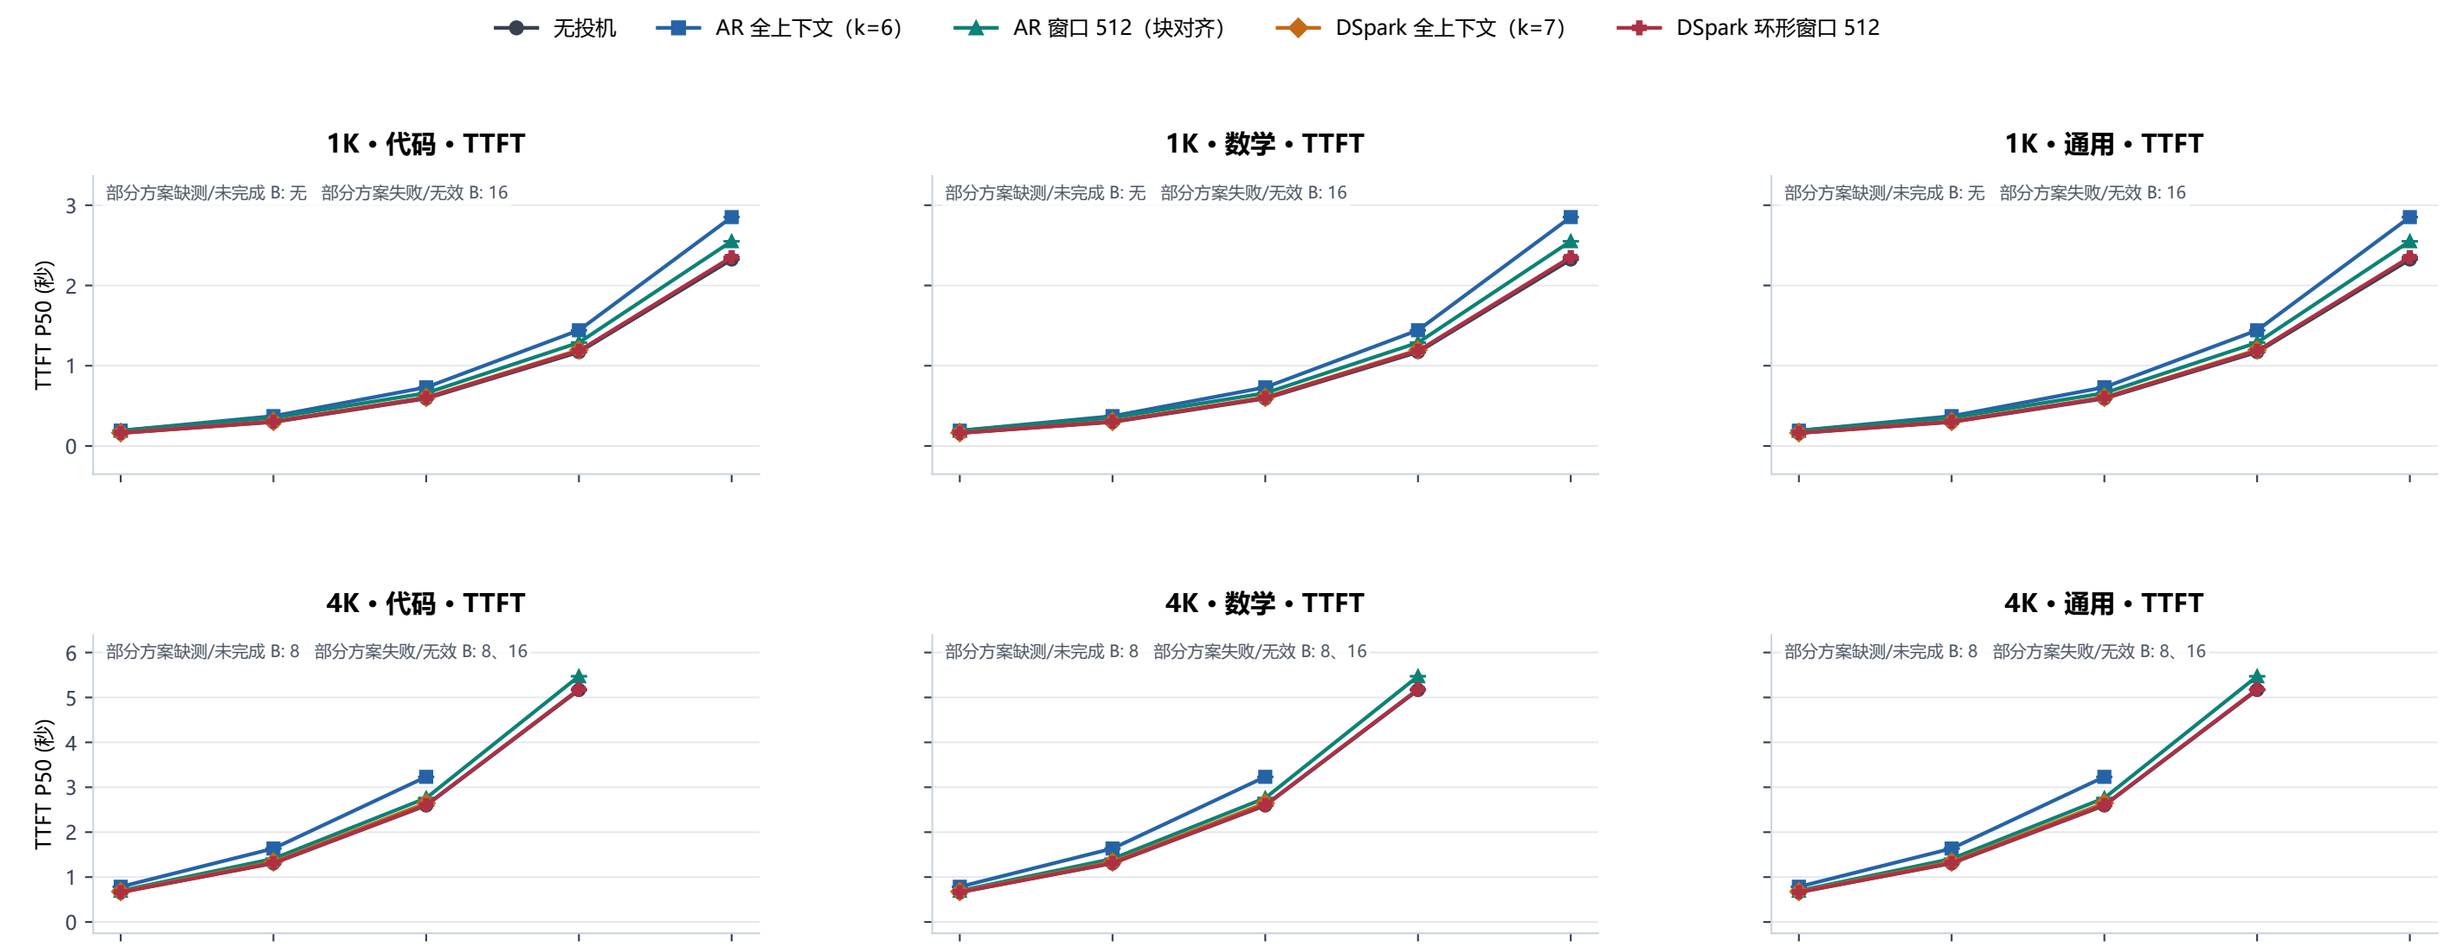
请求延迟：TTFT 与 TPOT

正式批量结束 · 覆盖不全

Qwen3-4B · 单卡 GPU-f1619d21-c909-7c21-34f1-05c39a7b0c91 · 显存预算 0.85 · T=1 · 输出256 · seed 20261105 · source 4a4a64b29192 · 每次先取请求 P50，再展示3次中位与范围



nano-vLLM 内部对照；prefix 关闭、在线 mixed 不支持；4K 为 Wiki 补齐吞吐面板，非任务质量测试。

误差线为3次测量的 min–max（不是置信区间）；缺测/失败不绘点、不跨缺口连线。